

Podstawowe statystyki

Średnia arytmetyczna:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Wariancja empiryczna:

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

Wariancja próbkowa:

$$S^{*2} = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Empiryczne odchylenie standardowe: $S = \sqrt{S^2}$

Próbkowe odchylenie standardowe: $S^* = \sqrt{S^{*2}}$

$$S^{*2} = S^2 \frac{n}{n-1}$$

Estymacja przedziałowa

Przedziały ufności dla wartości oczekiwanej

Model I

Cecha ma rozkład $N(\mu, \sigma)$ i wariancja σ^2 jest znana.

$$P\left(\bar{x} - u\left(1 - \frac{1}{2}\alpha\right)\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + u\left(1 - \frac{1}{2}\alpha\right)\frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$u\left(1 - \frac{1}{2}\alpha\right)$ - kwantyl rozkładu normalnego $N(0,1)$ rzędu $1 - \frac{1}{2}\alpha$

Model II

Cecha ma rozkład $N(\mu, \sigma)$, ale wariancja σ^2 jest nieznana.

$$P\left(\bar{x} - t\left(1 - \frac{1}{2}\alpha, n-1\right)\frac{S}{\sqrt{n-1}} \leq \mu \leq \bar{x} + t\left(1 - \frac{1}{2}\alpha, n-1\right)\frac{S}{\sqrt{n-1}}\right) = 1 - \alpha$$

lub (równoważnie)

$$P\left(\bar{x} - t\left(1 - \frac{1}{2}\alpha, n-1\right)\frac{S^*}{\sqrt{n}} \leq \mu \leq \bar{x} + t\left(1 - \frac{1}{2}\alpha, n-1\right)\frac{S^*}{\sqrt{n}}\right) = 1 - \alpha$$

$t\left(1 - \frac{1}{2}\alpha, n-1\right)$ - kwantyl rzędu $1 - \frac{1}{2}\alpha$ z rozkładu Studenta o $n-1$ stopniach swobody

Model III

Cecha ma rozkład nieznanym lub inny niż normalny. Dla konstrukcji przedziału ufności w tym przypadku musimy mieć próbę dużego rozmiaru. Zwykle zakłada się że $n > 30$ (niektórzy podają $n \geq 100$).

$$P\left(\bar{x} - u\left(1 - \frac{1}{2}\alpha\right)\frac{S^*}{\sqrt{n}} \leq \mu \leq \bar{x} + u\left(1 - \frac{1}{2}\alpha\right)\frac{S^*}{\sqrt{n}}\right) = 1 - \alpha$$

lub równoważnie

$$P\left(\bar{x} - u\left(1 - \frac{1}{2}\alpha\right)\frac{S}{\sqrt{n-1}} \leq \mu \leq \bar{x} + u\left(1 - \frac{1}{2}\alpha\right)\frac{S}{\sqrt{n-1}}\right) = 1 - \alpha$$

$u\left(1 - \frac{1}{2}\alpha\right)$ - kwantyl rozkładu normalnego $N(0,1)$ rzędu $1 - \frac{1}{2}\alpha$

Przedziały ufności dla wariancji

Model I

Cecha ma rozkład $N(\mu, \sigma)$, μ - znane, σ - nieznane

$$P\left(\frac{nS^2}{\chi^2\left(1 - \frac{1}{2}\alpha, n\right)} \leq \sigma^2 \leq \frac{nS^2}{\chi^2\left(\frac{1}{2}\alpha, n\right)}\right) = 1 - \alpha$$

$\chi^2\left(1 - \frac{1}{2}\alpha, n\right)$ - kwantyl rzędu $1 - \frac{1}{2}\alpha$ z rozkładu χ^2 o n stopniach swobody, $\chi^2\left(\frac{1}{2}\alpha, n\right)$ -

kwantyl rzędu $\frac{1}{2}\alpha$ z rozkładu χ^2 o n stopniach swobody,

Model II

Cecha ma rozkład $N(\mu, \sigma)$, μ, σ - nieznane

$$P\left(\frac{nS^2}{\chi^2\left(1 - \frac{1}{2}\alpha, n-1\right)} \leq \sigma^2 \leq \frac{nS^2}{\chi^2\left(\frac{1}{2}\alpha, n-1\right)}\right) = 1 - \alpha$$

lub (równoważnie)

$$P\left(\frac{(n-1)S^{*2}}{\chi^2\left(1 - \frac{1}{2}\alpha, n-1\right)} \leq \sigma^2 \leq \frac{(n-1)S^{*2}}{\chi^2\left(\frac{1}{2}\alpha, n-1\right)}\right) = 1 - \alpha$$

$\chi^2\left(1 - \frac{1}{2}\alpha, n-1\right)$ - kwantyl rzędu $1 - \frac{1}{2}\alpha$ z rozkładu χ^2 o $n-1$ stopniach swobody,

$\chi^2\left(\frac{1}{2}\alpha, n-1\right)$ - kwantyl rzędu $\frac{1}{2}\alpha$ z rozkładu χ^2 o $n-1$ stopniach swobody,

Przedziały ufności dla odchylenia standardowego – odchylenie standardowe to pierwiastek z wariancji, korzystając z tego faktu otrzymujemy:

Model II

Cecha ma rozkład $N(\mu, \sigma)$, μ, σ - nieznane

$$\left[\sqrt{\frac{nS^2}{\chi^2 \left(1 - \frac{1}{2}\alpha, n-1\right)}}, \sqrt{\frac{nS^2}{\chi^2 \left(\frac{1}{2}\alpha, n-1\right)}} \right]$$

lub (równoważnie)

$$\left[\sqrt{\frac{(n-1)S^{*2}}{\chi^2 \left(1 - \frac{1}{2}\alpha, n-1\right)}}, \sqrt{\frac{(n-1)S^{*2}}{\chi^2 \left(\frac{1}{2}\alpha, n-1\right)}} \right]$$

Przedziały ufności dla wskaźnika struktury

Badana cecha X ma w populacji generalnej rozkład zero-jedynkowy: $P(X=1) = p$,

$P(X=0) = 1-p$. p - wskaźnik struktury.

Model I

Liczność próby n : k elementów o wartości cechy równej 1, $n-k$ o wartości cechy równej 0.

$$\left[B_{\frac{\alpha}{2}}(k, n-k+1), B_{1-\frac{\alpha}{2}}(k+1, n-k) \right]$$

$B_q(n_1, n_2)$ - kwantyl rzędu q rozkładu Beta z parametrami n_1, n_2

Model II

Bardzo duża próba ($n \geq 100$)

$\hat{p} = \frac{k}{n}$ ma asymptotyczny rozkład normalny o parametrach $\mu = p$, $\sigma = \sqrt{\frac{p(1-p)}{n}}$, „przybliżony”

przedział ufności dla wskaźnika struktury:

$$\left[\hat{p} - u \left(1 - \frac{1}{2}\alpha\right) \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \hat{p} + u \left(1 - \frac{1}{2}\alpha\right) \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

$u \left(1 - \frac{1}{2}\alpha\right)$ - kwantyl rozkładu normalnego $N(0,1)$ rzędu $1 - \frac{1}{2}\alpha$

Jeżeli istnieje możliwość wyznaczenia kwantyli rozkładu Beta, to nie zaleca się korzystać z modelu przybliżonego.

Wyznaczanie minimalnej liczebności próby niezbędnej do uzyskania przedziału ufności o zadanej długości

Model I dla wartości oczekiwanej

Maksymalny błąd oszacowania (połowa długości przedziału ufności)

$$\Delta_{\max} = u \left(1 - \frac{1}{2} \alpha \right) \cdot \frac{\sigma}{\sqrt{n}}$$

Minimalna liczebność próby n_{\min} zapewniająca, że długość przedziału ufności nie przekroczy wartości d :

$$n_{\min} = \left\lceil \left(\frac{2u \left(1 - \frac{1}{2} \alpha \right) \cdot \sigma}{d} \right)^2 \right\rceil + 1$$

Symbol $[x]$ oznacza część całkowitą z liczby x (funkcja podłogi).

Model II dla wartości oczekiwanej

Maksymalny błąd oszacowania (połowa długości przedziału ufności)

$$\Delta_{\max} = t \left(1 - \frac{1}{2} \alpha, n-1 \right) \frac{S}{\sqrt{n-1}}$$

Zaleca się pobrać z populacji próbę wstępną o liczebności n_0 . Następnie oblicza się dla próby

wstępnej średnią arytmetyczną $\bar{x}_0 = \frac{1}{n_0} \sum_{i=1}^{n_0} x_i$, odchylenie standardowe $S_0 = \sqrt{\frac{1}{n_0} \sum_{i=1}^{n_0} (x_i - \bar{x}_0)^2}$

oraz kwantyl $t \left(1 - \frac{1}{2} \alpha, n_0 - 1 \right)$. Wyznacza się wartość m ze wzoru

$$m = \left\lceil \frac{2 \cdot t \left(1 - \frac{1}{2} \alpha, n_0 - 1 \right) \cdot S_0}{d} \right\rceil^2 + 1$$

Jeżeli

a) $m \leq n_0$, to $n_{\min} = n_0$.

b) $m > n_0$ - należy dobrać losowo $n_1 = [m] + 1 - n_0$ elementów do próby, wówczas

$n_{\min} = n_0 + n_1$. W tej sytuacji przedział ufności o długości nieprzekraczającej d ma postać

$$\left[\bar{x} - t \left(1 - \frac{1}{2} \alpha, n_0 - 1 \right) \cdot \frac{S_0}{\sqrt{n_0 + n_1 - 1}}, \bar{x} + t \left(1 - \frac{1}{2} \alpha, n_0 - 1 \right) \cdot \frac{S_0}{\sqrt{n_0 + n_1 - 1}} \right],$$

gdzie $\bar{x} = \frac{1}{n_0 + n_1} \sum_{i=1}^{n_0 + n_1} x_i$

Model III dla wartości oczekiwanej – postępujemy analogicznie jak w modelu I (wymagana jest duża liczebność próby) – w miejsce σ wstawiamy S^* .

Model II dla wskaźnika struktury

Mamy

$$n \geq \left(\frac{2u \left(1 - \frac{1}{2} \alpha \right) \cdot \sqrt{\hat{p}(1 - \hat{p})}}{d} \right)^2$$

W przypadku braku przesłanek, jaką wartość może mieć \hat{p} , przyjmuje się najbardziej „rygorystyczny” wariant, czyli $\hat{p} = 0.5$. Otrzymujemy

$$n_{\min} = \left\lceil \left(\frac{u \left(1 - \frac{1}{2} \alpha \right)}{d} \right)^2 \right\rceil + 1$$

Wymagana liczebność próby nie mniejsza niż 100.

Szczegóły są dostępne w skrypcie: Jolanta Borowska, *Wnioskowanie statystyczne z programem Maple. Część I*, Częstochowa 2021